

Caio Troiano Collino (1142491237), Thiago Pereira Lins da Silva
(1142515180), Vinícius Vianna Egydio de Carvalho (1142446597)

Otimização de overbooking em consultórios médicos utilizando teoria das filas

São Paulo

2026

Caio Troiano Collino (1142491237), Thiago Pereira Lins da Silva
(1142515180), Vinícius Vianna Egydio de Carvalho (1142446597)

Otimização de overbooking em consultórios médicos utilizando teoria das filas

Proposta de Trabalho de Conclusão de Curso
apresentado ao SENAC Santo Amaro como
requisito parcial para aprovação na disciplina
de TCC1 do curso de Ciência da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Curso de Ciência da Computação

Orientador: Prof. Afonso Lelis

São Paulo
2026

Resumo

Este documento apresenta a proposta inicial do Trabalho de Conclusão de Curso (TCC1) desenvolvido no SENAC Santo Amaro. O objetivo deste trabalho é reduzir a taxa de evasão e melhorar a experiência do usuário em clínicas médicas, ao mesmo tempo mantendo o lucro. A justificativa para este estudo baseia-se em [descrever brevemente a justificativa]. A revisão bibliográfica abrange [mencionar os principais tópicos]. Como solução proposta, pretende-se realizar a otimização do overbooking a partir do uso de simulação, modelos probabilísticos e teoria das filas. Este trabalho está organizado em três capítulos que apresentam a introdução ao tema, a revisão bibliográfica que fundamenta a pesquisa, o desenvolvimento com a solução proposta e o cronograma de trabalho, seguidos das referências bibliográficas.

Palavras-chave: palavra1. palavra2. palavra3. palavra4. palavra5.

Sumário

1	INTRODUÇÃO	4
1.1	Contexto	4
1.2	Justificativa	4
1.3	Objetivos	5
1.3.1	Objetivo geral	5
1.3.2	Objetivos específicos	5
2	REVISÃO BIBLIOGRÁFICA	7
2.1	Referencial teórico	7
2.2	Metodologia da pesquisa bibliográfica	7
2.3	Fundamentos	8
2.3.1	Overbooking	8
2.3.2	Métricas	8
2.3.3	Rede Neural Recorrente	9
2.4	Trabalhos relacionados	9
2.4.1	Trabalho 1: Appointment Capacity Planning With Overbooking for Outpatient Clinics With Patient No-Shows	9
2.4.2	Trabalho 2: Health care overbooking cost minimization model	9
2.4.3	Comparação	10
3	DESENVOLVIMENTO	11
3.1	Solução proposta	11
3.2	Cronograma de trabalho	12

1 Introdução

Este trabalho tem como tema a otimização do tempo no processo de diagnóstico neuropsicológico, considerando que o mesmo parte de uma suspeita inicial, passa pela procura de um profissional especializado e termina com a devolução de um diagnóstico completo. Esse processo, devido a sua natureza extensa e composição de múltiplas etapas, pode conter longos períodos de espera, ainda mais em um cenário de alta demanda e com um número limitado de profissionais na área. Ademais, um reconhecimento crescente na importância da avaliação neuropsicológica contribui para o aumento da procura por essa categoria de atendimento.

1.1 Contexto

No presente momento de desenvolvimento deste trabalho, observa-se uma grande procura por avaliações neuropsicológicas. A principal causa para essa busca reside na maior divulgação do tema em mídias tradicionais e digitais, especialmente em discussões relacionadas ao Transtorno do Espectro Autista (TEA) e outros transtornos do neurodesenvolvimento.

Contudo, quando uma pessoa busca por esse tipo de avaliação, ela constantemente se depara com longas filas de espera, um processo que excede o tempo esperado e até um intervalo maior que um ano desde a suspeita inicial até a devolução do diagnóstico. O período de espera até a conclusão do processo é um problema sério e relevante, já que ele atrasa intervenções, tratamentos, adaptações escolares, acadêmicas, profissionais e sociais.

Ademais, a falta de uma organização clara e processos bem definidos pode tornar o diagnóstico mais vulnerável a atrasos em múltiplas etapas. Considerando esse cenário, a computação tem uma contribuição significativa na análise, modelagem e melhoria do processo, tornando possível a identificação de gargalos, a simulação de cenários e a proposição de estratégias adequadas para tornar o fluxo de atendimento mais eficiente.

1.2 Justificativa

Por mais que existam diversos trabalhos na área acadêmica relacionados ao estudo de fluxos de trabalho em processos diagnósticos, muitos deles são direcionados a locais específicos, diagnósticos específicos ou contextos clínicos restritos. Como um processo amplo capaz de auxiliar na formação de diferentes diagnósticos, a avaliação neuropsicológica ainda é pouco explorada em um contexto de otimização computacional.

Assim sendo, este trabalho se justifica a partir de sua relevância social, acadêmica e prática. Atrasos ou ausências de diagnósticos podem resultar impactos significativos na vida dos pacientes, especialmente em um contexto escolar, acadêmico, profissional e social. Tanto crianças quanto adultos estão vulneráveis a esses impactos, tornando difícil o acesso a intervenções adequadas, adaptações necessárias e acompanhamento terapêutico.

A realização de diagnósticos em momentos adequados possibilita o início de tratamentos, terapias, adaptações pedagógicas e outras formas de suporte para o paciente. Contudo, busca-se estudar meios capazes de reduzir o tempo de espera do processo de diagnóstico sem nenhum prejuízo no tempo mínimo necessário para garantir precisão, qualidade e confiabilidade na avaliação.

1.3 Objetivos

1.3.1 Objetivo geral

O objetivo deste trabalho é propôr um modelo estatístico utilizando conceitos de pesquisa operacional, simulação de eventos discretos e teoria das filas, com o fim de diminuir o tempo mínimo para um paciente receber o diagnóstico dentro do processo de avaliação neuropsicológica, partindo da primeira consulta no psiquiatra, até o retorno dos resultados do exame.

1.3.2 Objetivos específicos

Para o desenvolvimento do projeto, é necessário compreender a linha de processos envolvida em um diagnóstico, identificando cada uma das etapas desde o início do atendimento até a entrega do diagnóstico. Esse mapeamento torna possível a compreensão do funcionamento do processo, tornando viável o reconhecimento de pontos críticos, atrasos e falhas capazes de comprometer o tempo de diagnóstico. Essa análise torna plausível a identificação do momento onde ocorre o principal gargalo do sistema, ou seja, a sessão do processo onde existe o maior tempo de espera. Este gargalo pode estar presente em diversos momentos do processo, como na fila de espera para o atendimento inicial, no intervalo entre a realização dos exames e a devolução do diagnóstico ou em outras fases intermediárias.

Com isso, será construído um modelo de processos capaz de representar o funcionamento dos mesmos. Esse modelo será capaz de testar múltiplos cenários, tornando possível a avaliação de como mudanças na organização do atendimento, na distribuição de recursos ou no fluxo de pacientes podem impactar o tempo de espera de devoluções. Depois da criação do modelo, simulações serão realizadas com o intuito de observar como o processo se comporta em diferentes condições para comparar cenários e identificar alternativas mais eficientes. Por último, em função dos resultados obtidos nas simulações, será desenvolvido

um algoritmo de otimização com a finalidade de propor melhorias capazes de reduzir gargalos e tornar o processo de diagnóstico mais rápido.

2 Revisão bibliográfica

2.1 Referencial teórico

2.2 Metodologia da pesquisa bibliográfica

A pesquisa bibliográfica foi conduzida a partir da consulta a diferentes bases de dados acadêmicas e científicas, com o objetivo de identificar trabalhos relevantes sobre o tema. Dentre as bases, foram consultadas: *Google Scholar* e *Semantic Scholar*, onde foram considerados trabalhos publicados entre 2021 e 2026, nos idiomas português, inglês e espanhol, incluindo artigos científicos e estudos de caso.

Em cada base, foi utilizado um conjunto de strings de busca, onde, dado os resultados, foram selecionados artigos e estudos condizentes com a proposta deste trabalho. Segue abaixo uma tabela com os resultados obtidos, com base na string de busca e plataforma:

Tabela 1 – Resultados de busca nas bases de artigos

Base(s)	String de busca	Resultados da busca	Artigos Seleccionados
<i>Google Scholar</i>	"redução do tempo de espera"ambulatório simulação	59	7
<i>Google Scholar</i>	("teoria das filas"OR "modelo de filas") AND ("medicina"OR "saúde"OR "clínica") AND ("simulação"OR "mobile")	210	5
<i>Semantic Scholar</i>	"discrete event simulation patient flow"healthcare bottleneck optimization	98	4
<i>Google Scholar</i>	"simulação de eventos"fundamentos "saúde"OR "clínica-criptografia -emergência	103	2
<i>Google Scholar</i>	"healthcare workflow optimization"waiting time bottleneck	31	2

Fonte: Elaborado pelo autor (2026)

A partir dos resultados, foi realizado a seleção dos artigos e suas citações, aplicando a técnica de "funil", no qual realiza-se o filtro dos artigos mais relevantes, para definir os artigos principais relacionados a este trabalho.

Vale ressaltar que houve um contraste grande nos resultados da busca em relação à quantidade de artigos selecionados devido aos seguintes fatores:

- **Aderência ao tema:** Muitos artigos não tinham, ou haviam pouca relação com o tema deste trabalho, sendo excluídos da seleção;
- **Abordagens e problemas repetidos:** Como há muitos artigos com as mesmas abordagens ou os mesmos problemas, foram selecionados apenas os artigos nos quais haviam abordagens ou problemas diferentes uns dos outros;
- **Deduplicação de artigos:** Dado as strings de busca acima, houveram artigos duplicados entre as buscas, sendo necessário a deduplicação dos artigos. Essa etapa foi feita através da ferramenta *ResearchRabbit*, como centralizador de artigos.

Ao todo, foram totalizados 25 artigos selecionados para a aplicação do funil, onde 20 artigos foram selecionados via string de busca, e 5 artigos foram selecionados via *Google Scholar Labs* através de *prompts*. Foram selecionados 5 artigos como potenciais candidatos à trabalhos relacionados, e dentre eles, 3 aptos como trabalhos relacionados. 2 dos 5 trabalhos candidatos não foram selecionados por conta dos seguintes critérios:

- Semelhança entre os trabalhos eleitos;
- Menor referencial teórico em relação aos trabalhos eleitos;
- Os trabalhos eleitos abordavam problemas semelhantes, ou o mesmo problema.

2.3 Fundamentos

2.3.1 Overbooking

O *overbooking* é a venda de um número de produtos ou serviços em maior número que o estoque atual ou a capacidade de serviço, sendo aplicado principalmente nas áreas da saúde e da aviação. O *overbooking* surgiu como uma maneira de compensar o lucro perdido por conta de clientes que não comparecem ou cancelam o serviço (Denominado como *no-shows*), utilizando todo o estoque ou capacidade do serviço disponível para balancear a eficiência operacional e a qualidade do serviço. No contexto clínico, o principal *trade-off* do *overbooking* é entre a eficiência operacional e a qualidade do serviço: segundo Zeng et al. (2013), o maior uso da equipe médica derivado do *overbooking* pode trazer benefícios como maior lucro e redução do atraso para conseguir uma consulta (*appointment-delay*). Porém, essa prática aumenta o tempo de espera no consultório para ser atendido (*office-delay*) e pode até reduzir o lucro da clínica para valores críticos de *panel-size*.

2.3.2 Métricas

Para avaliar o modelo, serão utilizadas métricas baseadas na qualidade e eficiência de serviço, levando em consideração o *overbooking* e a estabilidade da clínica. A partir disso,

escolhemos trabalhar com o tempo médio de *office-delay*, o tempo do *appointment-delay* e a taxa de *no-shows*. Também serão utilizadas outras métricas como a taxa de utilização de recursos para garantir estabilidade.

2.3.3 Rede Neural Recorrente

Uma Rede Neural Recorrente (Referenciada pela sigla em inglês RNN – *Recurrent Neural Network*) é uma rede neural profunda, com diversas camadas escondidas, treinada a partir de dados sequenciais ou séries temporais, com o objetivo de criar um modelo de aprendizado de máquina para realizar previsões. O principal diferencial das RNNs está em sua capacidade de utilizar informações de entradas prévias para influenciar o valor atual de entradas e saídas. Para uma determinada entrada, a RNN mantém um estado oculto, responsável por acompanhar o contexto e agir como uma memória que armazena informações das entradas anteriores, processando a entrada atual junto com o estado oculto da etapa anterior em cada etapa, dando uma capacidade de "lembrar" dados anteriores, influenciando o valor da saída atual. No contexto clínico, utilizaremos a RNN para prever a probabilidade de *no-shows* e ajustar o nível de *overbooking* em função do modelo.

2.4 Trabalhos relacionados

Com base no nosso problema, e na nossa proposta de solução, encontramos 3 artigos relevantes, com problemas e soluções semelhantes.

2.4.1 Trabalho 1: Appointment Capacity Planning With Overbooking for Outpatient Clinics With Patient No-Shows

Este trabalho abordou o problema de aderência dos pacientes, juntamente com a grande lista de espera em clínicas. Nele, utiliza-se provas matemáticas para comprovar a eficácia do modelo, enquanto no nosso trabalho utilizaremos ferramentas diferentes e olhando para o *overbooking* como causa do problema.

Além disso, é possível observar que a falta de métricas como o tempo de fila e o tempo de atendimento causa uma limitação na coleta de resultados, ou seja, com essa coleta, teremos mais visibilidade em relação à experiência do paciente.

2.4.2 Trabalho 2: Health care overbooking cost minimization model

Esse trabalho aborda a resolução do *overbooking* no sistema de saúde, otimizando valores a partir de um modelo, de forma que o número escolhido de *overbooking* seja o melhor, otimizando sua eficiência. Dado os resultados, conclui-se que temos o prejuízo

pela falta de organização, e não pelo *overbooking* em si. Além disso, há problemas como a complexidade, necessidade de dados e o custo financeiro para a implementação do estudo. Outra dificuldade encontrada no trabalho foi a generalização do modelo, na qual foi voltada para uma rede de hospitais da Arábia Saudita, além de haver certas informações que foram ignoradas, como idade, gênero, condição de saúde, e geolocalização.

Tabela 2 – Comparação entre trabalhos relacionados

Critério	Trabalho 1	Trabalho 2	Este trabalho
Objetivo	O problema de aderência dos pacientes, juntamente com a grande lista de espera em clínicas	Resolução do <i>overbooking</i> no sistema de saúde, otimizando valores	Organização do <i>overbooking</i> eventualmente impactando no aumento do lucro e na melhor experiência para o paciente
Tecnologia	Utiliza-se provas matemáticas para comprovar a eficácia do modelo	Modelo para definir o número escolhido de <i>overbooking</i> seja o melhor, otimizando sua eficiência	Uso de RNN para prever <i>no-shows</i>
Validação	Provas matemáticas para comprovar a eficácia do modelo	Dado os resultados, conclui-se que temos o prejuízo pela falta de organização, e não pelo <i>overbooking</i> em si	Combinação de conceitos matemáticos e estatísticos
Limitação	Falta de métricas como o tempo de fila e o tempo de atendimento causa uma limitação na coleta de resultados	Complexidade, necessidade de dados, custo financeiro, dificuldade de generalização (rede de hospitais da Arábia Saudita) e ausência de informações como idade, gênero, condição de saúde e geolocalização	—

Fonte: Elaborado pelo autor

2.4.3 Comparação

Notamos que ambos os trabalhos tratam do mesmo assunto, que são problemas em clínicas médicas. Porém vemos abordagens diferentes e resultados diferentes, onde ambos podem ser utilizados como base para melhor nosso trabalho, gerando uma combinação de conceitos matemáticos e estatísticos do primeiro artigo, junto com a ideia de criar um modelo e "organizar" o *overbooking* eventualmente impactando no aumento do lucro e na melhor experiência para o paciente. Ou seja, nosso trabalho olha para ambos e complementa usando RNN para prever *no-shows*.

3 Desenvolvimento

Neste capítulo, apresenta-se a solução proposta para o problema identificado, bem como o cronograma de trabalho previsto para o desenvolvimento completo do projeto no TCC2.

3.1 Solução proposta

A solução proposta do trabalho constitui-se na criação de um modelo de processos capaz de analisar e otimizar o fluxo de diagnóstico neuropsicológico em clínicas. O principal objetivo do modelo será a representação das etapas essenciais do processo desde a suspeita inicial e procura pelo atendimento especializado até a realização de exames, análise dos resultados e devolução do diagnóstico.

A solução será constituída por três principais partes: o mapeamento do processo, a criação de um modelo de simulação e a otimização. A princípio, será efetuado uma listagem das etapas responsáveis por compor o processo de diagnóstico neuropsicológico, com fim de identificar os principais momentos de espera, recursos envolvidos, profissionais necessários e pontos em que o atraso é uma possibilidade. O mapeamento tornará possível a compreensão do funcionamento do fluxo de atendimento e servirá como a essência da criação do modelo.

A seguir, um modelo com a capacidade de representar a clínica e seu funcionamento em diferentes cenários será desenvolvido. O modelo necessitará levar em consideração elementos como entrada de pacientes, disponibilidade de profissionais, número de sessões, tempo médio entre etapas e devolução do diagnóstico. Com isso, será possível a simulação do comportamento do processo e a observação de como determinadas variações podem alterar o tempo total de espera.

A arquitetura da solução é dividida em 3 camadas: a primeira camada é responsável pela coleta e estruturação das informações do processo, a segunda pelo modelo de simulação, e a terceira pelo módulo de análise e otimização. A camada de coleta e estruturação contém dados relacionados a etapas do diagnóstico, disponibilidade de recursos e volume de pacientes. A camada do modelo de simulação é responsável pela representação do fluxo de atendimento e a execução de diferentes cenários. A camada do módulo de análise e otimização é encarregada a identificar gargalos e propor alternativas que permitam a redução de atrasos sem comprometer a qualidade e a confiabilidade da avaliação neuropsicológica.

Python será a linguagem utilizada devido à sua vasta gama de bibliotecas com foco em análise estatística, manipulação de dados e simulação de processos. Serão utilizadas as bibliotecas Pandas e NumPy para auxiliar a organização e tratamento de dados. SimPy será utilizado devido a sua capacidade de representação de filas, recursos e eventos discretos com o passar do tempo.

Como as principais funcionalidades da solução, teremos: mapeamento do processo de diagnóstico neuropsicológico, representação do fluxo de atendimento, identificação de gargalos, simulação de diferentes cenários de funcionamento e a identificação de alternativas de melhoria. Dentre os cenários possíveis, será plausível o teste de mudanças como o aumento ou redistribuição de profissionais, alteração na ordem de etapas, reorganização de agenda e redução de períodos ociosos entre fases do processo.

Será adotada uma metodologia de desenvolvimento baseada em prototipação e simulação. Será inicialmente criado um modelo simplificado do processo contendo as principais etapas identificadas. Posteriormente, o modelo será refinado de acordo com os dados levantados e os gargalos encontrados. Com base nisso, serão executadas simulações com fim de comparar o funcionamento do processo em condições diferentes. Essa metodologia incremental permitirá o ajuste do modelo progressivamente, garantindo sua representação de forma mais adequada ao problema.

Os critérios de avaliação estão ligados com a capacidade do modelo de representação do processo de diagnóstico e da indicação de melhorias viáveis. Serão utilizadas métricas como tempo médio total até a devolução do diagnóstico, tempo médio de espera em cada etapa, tamanho das filas, taxa de utilização dos profissionais e identificação do principal gargalo do sistema. Ademais, simulações de cenários simulados serão comparadas entre si com o intuito de verificar as estratégias que apresentam melhores resultados no que diz respeito à redução do tempo de espera, mantendo a qualidade necessária para realizar uma avaliação confiável.


3.2 Cronograma de trabalho

O cronograma a seguir apresenta, no formato de diagrama de Gantt, as atividades previstas para o desenvolvimento do TCC2, distribuídas ao longo das semanas do semestre.

Instruções para personalização do cronograma:

- Ajuste o número de semanas conforme o calendário acadêmico do semestre;
- Modifique as atividades de acordo com as etapas do seu projeto;
- Os marcos (*milestones*) indicam entregas importantes — adapte-os às datas de avaliação;
- As setas entre atividades indicam dependências — uma atividade só inicia após a conclusão da anterior;
- Utilize o diagrama como ferramenta de acompanhamento: atualize-o a cada reunião com o orientador.

Figura 1 – Cronograma de atividades – Diagrama de Gantt



Fonte: Elaborado pelo autor (2025)